

Incorporando o Erro de Mensuração da Teoria da Resposta ao Item para Respostas Contínuas em Desfechos Distais Dicotômicos: uma Abordagem Bayesiana

Ingo Dube Souza¹

¹Programa de Pós Graduação em Estatística e Ciência de Dados
(PGECD/UFBA), Estudos Econômicos (SENAI/CIMATEC)
`ingo.dube@ufba.br`

Resumo

A Teoria da Resposta ao Item (TRI) é amplamente utilizada na modelagem de variáveis latentes em avaliação educacional e psicometria, cujas respostas empregadas usualmente são dicotômicas ou politômicas. Entretanto, modelos da TRI cujo objetivo é estimar traços latentes baseados em respostas contínuas (CRM) têm ganhado maior relevância, sendo o modelo de respostas Normais, um dos mais utilizados. Além disso, a estimação do traço latente muitas vezes não é o objetivo final, mas sim o efeito dele em um desfecho observado. Neste contexto, a literatura indica que, quando um construto é tratado como observado e é utilizado como preditor de uma resposta também observada, seu efeito sobre o desfecho tende a ser subestimado. Como forma de contornar esse problema, este trabalho propõe uma abordagem bayesiana que estima conjuntamente a TRI e a regressão, incorporando a incerteza associada ao traço latente e, assim, permitindo uma correção assintótica do viés na estimação de seu efeito sobre o desfecho. Para avaliar o desempenho da proposta, foi conduzido um estudo de simulação comparando um método de estimação realizada em duas etapas e uma abordagem bayesiana de estimação conjunta da TRI e da regressão. Os resultados obtidos indicam que, quando comparados, o método de estimação conjunta corrige o viés do efeito do construto sobre a resposta distal, sobretudo à medida que o tamanho amostral aumenta. Outrossim, o estudo também concluiu que a estimação simultânea da TRI e da regressão não prejudicou ou causou vieses na estimação tanto da variável latente quanto dos parâmetros dos itens.

Keywords: TRI; Regressão; Resposta Distal; MCMC; Algoritmo EM.

1 Introdução

Diferentemente das variáveis de mensuração direta e explícita comumente utilizadas na ciência de dados, fenômenos complexos como habilidades e comportamentos constituem variáveis latentes, cuja natureza não observável implica inerente subjetividade e erro de medida. Originado nos estudos de [Spearman \(1904\)](#) sobre a inteligência humana e fundamentando o desenvolvimento da Análise Fatorial, esse conceito define tais variáveis como construtos teóricos que, embora não passíveis de observação direta, podem ser estimados estatisticamente por meio de indicadores observados ([Bollen, 1989](#)).

O tipo de método empregado para modelar variáveis latentes depende se o construto está na escala contínua, ou está dividido em classes latentes. Da mesma forma, a natureza dos indicadores, sejam eles contínuos ou categóricos, também influenciam na escolha da metodologia utilizada. Uma das abordagens utilizadas na literatura é a Teoria da Resposta ao Item (TRI), que modela a relação entre um traço latente na escala contínua e a probabilidade de um indivíduo obter um determinado resultado em um teste ([Hambleton et al., 1991](#)). Apesar do amplo uso da TRI no contexto psicométrico ou de avaliação educacional, a TRI possui um caráter multidisciplinar, podendo ser aplicadas nas mais diversas áreas do conhecimento ([Hays et al., 2007](#); [Knoll e Houts, 2012](#); [Hare e Poole, 2018](#)).

Os modelos iniciais da TRI propostos por [Lord \(1952\)](#), [Rasch \(1960\)](#) e [Birnbaum \(1968\)](#) consideram itens dicotômicos, isto é, se um indivíduo respondeu corretamente a um item de um teste ou não. Posteriormente, [Samejima \(1969\)](#) estendeu a abordagem dicotômica para itens politômicos com o Modelo de Respostas Graduais (GRM, do inglês. *Graded Response Models*), modelando a probabilidade de um indivíduo responder a uma determinada categoria ordinal de um teste. A partir disso, outras abordagens para respostas categóricas foram formuladas, como o Modelo para Respostas Nominais ([Bock, 1972](#)), Modelo da Escala Gradual ([Andrich, 1978](#)) e o Modelo do Crédito Parcial ([Masters, 1982](#); [Muraki, 1992](#)).

Não obstante, [Samejima \(1973\)](#) observou uma necessidade de incorporação de respostas na escala contínua na estimação da variável latente pela TRI. Isso se deve ao fato de que, em testes psicométricos, respostas contínuas podem ser obtidas, de duas formas. A primeira é pela mensuração do tempo até a finalização de uma determinada atividade ([Roskam, 1997](#); [Van der Linden, 2006](#); [Ferrando e Lorenzo-Seva, 2007](#)). A segunda forma é quando testes são respondidos utilizando escalas visuais analógicas em segmento de reta ([Cella e Perry, 1986](#); [Guyatt et al., 1987](#); [Ferrando, 2001](#)).

Existe uma terceira forma de se obter respostas contínuas normais para a mensuração de um traço latente, que é padronização de variáveis indicadoras contínuas utilizando o método do *z-score*. Neste caso, variáveis que são medidas em escalas distintas são postas em uma mesma escala para comparar quantos desvios padrão um valor específicos está acima ou abaixo da média. Esse tipo de abordagem é muito comum na construção de índices sintéticos ([OCDE, 2008](#)), nos quais o uso da TRI é aplicável ([Filmer e Scott, 2012](#); [Vandemoortele, 2014](#)).

Dessa forma, [Samejima \(1973\)](#) formalizou o Modelo de Respostas Contínuas (CRM, do inglês, *Continuous Response Model*) para respostas limitadas ao intervalo 0 e 1 e usando a distribuição ogiva normal para modelar o traço latente. [Wang e Zeng \(1998\)](#) propuseram uma reparametrização do modelo de Samejima ao aplicar uma transformação logarítmica às respostas contínuas, ainda associado à distribuição normal. Para a estimação frequentista dos parâmetros dos itens no CRM, os autores desenvolveram uma abordagem por máxima verossimilhança marginal com o auxílio do algoritmo de Esperança-Maximização (EM) ([Dempster et al., 1977](#)).

Em muitas aplicações, contudo, a estimação da variável latente não é o ponto final

da análise. O traço estimado pode ser utilizado como variável explicativa em modelos de regressão para investigar sua associação com respostas observadas, denotadas por desfechos distais. Schofield (2008) discute que escores de testes cognitivos, quando usados como preditores em modelos de regressão, carregam erro de mensuração que não deve ser ignorado. Não obstante, ao tratar uma variável latente estimada como se fosse observada sem erro, os coeficientes de regressão podem se tornar enviesados, com tendência de atenuação do efeito associado ao preditor medido com erro (Junker *et al.*, 2012; Schofield *et al.*, 2015).

A literatura sobre regressão com escores fatoriais e modelos de estrutura latente também aponta que procedimentos em etapas, nos quais escores latentes preditos são posteriormente tratados como observados, podem subestimar associações estruturais (Skrondal e Laake, 2001; Bolck *et al.*, 2004; Devlieger *et al.*, 2016). Embora Schofield (2008) tenha enfatizado aplicações em regressão linear, a própria formulação baseada em modelos de mensuração e modelos estruturais permite extensão para modelos lineares generalizados, incluindo modelos para respostas dicotômicas. Nesse contexto, abordagens bayesianas são particularmente úteis porque permitem estimar simultaneamente o modelo de mensuração e o modelo de regressão, propagando a incerteza da variável latente para a inferência sobre o desfecho distal (Fox e Glas, 2003; Junker *et al.*, 2012).

Considerando que, embora existam propostas para modelagem de respostas contínuas no contexto da TRI, essa linha de pesquisa permanece relativamente pouco explorada quando comparada ao vasto desenvolvimento dos modelos para dados categóricos. Além disso, o uso de modelos de equações simultâneas com análise fatorial confirmatória como modelo de mensuração é amplamente utilizado na literatura (Kline, 1998). Apesar disso, os modelos contínuos da TRI são perfeitamente comparáveis à análise fatorial (Mellenbergh, 1994; Ferrando, 2002), oferecendo outras vantagens, como a interpretação de cada um dos itens com base em parâmetros de discriminação ou de dificuldade, bem como na avaliação do padrão de respostas dos indivíduos (Ferrando, 1999, 2010).

Ademais, existe uma predominância de abordagens de estimação frequentista na literatura, tanto para os modelos categóricos (Hambleton *et al.*, 1991), quanto para os recentes desenvolvimentos dos modelos contínuos (Tutz e Jordan, 2024). Em contrapartida, as formulações bayesianas oferecem maior flexibilidade para a modelagem da estrutura de mensuração, incorporação de incerteza e extensão a abordagens mais complexas (Fox, 2010).


Assim sendo, este trabalho tem como objetivo geral utilizar a variável latente estimada pela TRI utilizando itens contínuos como preditor em um modelo de regressão logística para um desfecho distal dicotômico. Especificamente, busca-se comparar uma abordagem em duas etapas, na qual primeiro se estima o CRM por máxima verossimilhança marginal com otimização via algoritmo EM e depois se trata a variável latente estimada como observada na regressão logística, com uma abordagem bayesiana de estimação conjunta da TRI e da regressão. Por meio de um estudo com dados simulados, pretende-se atestar se a estimação bayesiana conjunta corrige a subestimação do efeito da variável latente sobre a resposta distal quando comparada à abordagem em duas etapas.

2 Metodologia

O modelo proposto considera um único traço latente θ_i , definido em escala contínua para cada indivíduo $i = 1, 2, \dots, n$. Além disso, seja Y_{ij} as variáveis indicadoras observadas com $j = 1, 2, \dots, p$, também definidas na escala contínua. Neste contexto, é definido o modelo de mensuração do construto em que as variações dos indicadores são explicadas pela variação do traço latente (Bollen, 1989).

Seja W_i uma variável de desfecho observada, denotada por resposta distal, cujo preditor não é observado diretamente. Neste caso, é definida a regressão estrutural, em que W_i é modelado condicionalmente a θ_i . Dessa forma, o Modelo Estrutural apresentado na Figura 1 representa a combinação de um Modelo de Mensuração com a Regressão Estrutural [Kline \(1998\)](#).

Figura 1: Representação por diagrama de caminhos de um Modelo Estrutural.



Em termos gerais, a estrutura apresentada permite avaliar em que medida diferenças individuais no traço latente afetam a também a variação de uma variável exógena observada diretamente.

2.1 Teoria da Resposta ao Item para Respostas Contínuas

O Modelo de Mensuração proposto definido pelo CRM o qual é baseado na formulação original de [Samejima \(1973, 1974\)](#). Considerando uma amostra de tamanho n e um teste com p itens, seja Y_{ij} o escore observado do i -ésimo indivíduo no j -ésimo item, tal que $0 \leq Y_{ij} < k_j$, $\forall i = 1, 2, \dots, n, j = 1, 2, \dots, p$. Assim sendo, [Wang e Zeng \(1998\)](#) propuseram a seguinte transformação:

$$Z_{ij} = \ln \left(\frac{Y_{ij}}{k_j - Y_{ij}} \right) \iff Y_{ij} = \frac{k_j \exp\{Z_{ij}\}}{1 + \exp\{Z_{ij}\}}. \quad (1)$$

Aplicando a transformação apresentada na Equação (1) sobre a função de integração original de [Samejima \(1973\)](#), a função densidade de probabilidade de Z_{ij} é definida por:

$$f_Z(z_{ij} | \theta_i, a_j, b_j, \alpha_j) = \frac{a_j}{\sqrt{2\pi\alpha_j^2}} \exp \left\{ - \frac{\left[a_j \left(\theta_i - b_j - \frac{z_{ij}}{\alpha_j} \right) \right]^2}{2} \right\}. \quad (2)$$

em que θ_i é o traço latente do i -ésimo indivíduo, $\theta_i \in \mathbb{R}, \forall i = 1, 2, \dots, n$. a_j , b_j e α_j são os parâmetros da TRI, representando respectivamente a discriminação, dificuldade e escala referentes ao j -ésimo item, tal que $a_j > 0, b_j \in \mathbb{R}, \alpha_j > 0, \forall j = 1, 2, \dots, p$. Ao analisar a estrutura da Equação (2), é fácil ver que $Z_{ij} | \theta_i, a_j, b_j, \alpha_j$ possui a seguinte distribuição de probabilidade:

$$Z_{ij} | \theta_i, a_j, b_j, \alpha_j \sim \mathcal{N} \left(\alpha_j (\theta_i - b_j), \frac{\alpha_j^2}{a_j^2} \right). \quad (3)$$

Para implementar o ajuste de qualquer modelo da TRI para a estimação de um único traço latente, faz-se necessário que o teste seja unidimensional, isto é, as respostas observadas precisam estar mensurando, em grande parte, uma única variável latente (Fox, 2010). Essa suposição pode ser verificada por uma análise de correlação entre as respostas dos itens dois a dois. O desejado é que as correlações sejam todas positivas e estatisticamente diferentes de zero.

Adicionalmente, as respostas aos itens precisam ser independentes quando condicionadas ao traço latente. Conforme visto por Hambleton *et al.* (1991), a unidimensionalidade implica independência local, portanto a verificação da primeira suposição já garante que a segunda também é verdadeira. Por fim, há uma terceira suposição de que o traço latente está distribuído seguindo uma distribuição Normal padrão. Apesar de estudos aplicados com a TRI se basearem nesta suposição, é possível ajustar modelos da TRI considerando distribuições não normais para o traço latente (Zhang *et al.*, 2021).

2.2 Regressão Logística

A Regressão Logística não modela diretamente o desfecho, mas sim a probabilidade condicional de que a variável resposta assuma o valor 1 (sucesso) dado um conjunto de preditores (Cox e Hinkley, 1979). Seja W_i a resposta distal binária para o i -ésimo indivíduo (i.e., $W_i \in \{0, 1\}, \forall i = 1, 2, \dots, n$), a Equação (4) descreve a função logito, a qual lineariza a relação entre um preditor observado X e o desfecho binário:

$$\eta_i = \ln \left[\frac{P(W_i = 1 | X_i)}{1 - P(W_i = 1 | X_i)} \right] = \beta_0 + \beta_1 X_i. \quad (4)$$

Da mesma forma, define-se q_i como:

$$q_i = \frac{1}{1 + \exp [-(\beta_0 + \beta_1 X_i)]}. \quad (5)$$

Como q_i é uma probabilidade (i.e., $0 \leq q_i \leq 1, \forall i = 1, 2, \dots, n$), então a distribuição de $W_i | X_i, \beta_0, \beta_1$ é dada como:

$$W_i | X_i, \beta_0, \beta_1 \sim \text{Bern}(q_i). \quad (6)$$

2.3 Métodos de Estimação

Considerando o CRM como modelo de mensuração e a regressão logística como a regressão estrutural, o processo de estimação deve ser capaz de estimar o modelo que esteja de acordo com a estrutura apresentada na Figura 1. Para tanto, serão comparadas a abordagem de estimação em duas etapas, e a estimação simultânea da TRI e da regressão.

2.3.1 Estimação em Duas Etapas

Quando o processo de estimação é realizado em duas etapas, inicialmente estima-se todos os θ_i com base nas variáveis observadas Y_{ij} . O modelo de mensuração utiliza as transformações definidas na Equação (1) e a distribuição de probabilidade definida na Equação (2). Assumindo independência condicional dos itens dado θ_i e considerando o vetor de parâmetros dos itens $\mathbf{\Lambda} = \{a_1, a_2, \dots, a_p, b_1, b_2, \dots, b_p, \alpha_1, \alpha_2, \dots, \alpha_p\}$, a densidade

condicional do vetor de respostas transformadas do i -ésimo indivíduo descritos na Equação (3) é dada por:

$$f_Z(z_i | \theta_i, \Lambda) = \prod_{j=1}^p f_Z(z_{ij} | \theta_i, a_j, b_j, \alpha_j).$$

Logo, a densidade marginal de Z_i é dada por:

$$f_Z(z_i | \Lambda) = \int f_Z(z_i | \theta_i, \Lambda) g_\theta(\theta_i),$$

em que $g_\theta(\theta_i)$ é a densidade de θ_i , usualmente normal padrão (Zhang *et al.*, 2021). Desse modo, a log-verossimilhança marginal do CRM é definida como:

$$\ell(Z, \Lambda) = \sum_{i=1}^n \ln \left\{ \int \left[\prod_{j=1}^p f_Z(z_{ij} | \theta_i, a_j, b_j, \alpha_j) \right] g_\theta(\theta_i) d\theta_i \right\}. \quad (7)$$

A integral presente na Equação (7) torna a maximização direta difícil. Sendo assim, o algoritmo EM resolve esse impasse tratando θ_i como uma variável latente. O detalhamento da álgebra essencial para a implementação do método, bem como as regras de atualização dos parâmetros podem ser vistos no trabalho de Wang e Zeng (1998). Esse método estima primeiro os parâmetros de todos os p itens no processo chamado de calibração da TRI e posteriormente os θ_i são estimados dado o procedimento de calibração.

Entretanto, o custo computacional de cada ciclo EM para a estimação dos parâmetros da TRI é extremamente alto, tendendo a ser impraticável em amostras grandes. Para solucionar esse problema, Shojima (2005) propôs uma solução não iterativa em cada ciclo EM para o CRM normal, explorando formas explícitas no passo de esperança e soluções fechadas no passo de maximização sob prioris vagas para os parâmetros dos itens. Essa abordagem reduz significamente o tempo computacional do processo de estimação e está implementada no pacote **EstCRM** no R (Zopluoglu, 2012). Foi considerado o limiar de 10^{-4} como critério de convergência com limite máximo de 1000 iterações por ciclo EM.

A segunda etapa envolve a estimação da regressão utilizando os $\hat{\theta}_i$ estimados pelo modelo de mensuração. Neste caso, a Equação (4) é reescrita em função de $\hat{\theta}_i$.

$$\eta_i = \ln \left[\frac{P(W_i = 1 | \hat{\theta}_i)}{1 - P(W_i = 1 | \hat{\theta}_i)} \right] = \beta_0 + \beta_1 \hat{\theta}_i \implies q_i = \frac{1}{1 + \exp[-\eta_i]} \quad (8)$$

Segundo Schofield (2008), quando uma variável latente é tratada como observada em um modelo de regressão, ela carrega um erro de mensuração o qual não é observado e, portanto, não é incorporado no modelo de regressão. Assim sendo, $\hat{\theta}_i$ pode ser escrito como $\hat{\theta}_i = \theta_i + u_i$, em que u_i é o erro de mensuração da variável latente e que também não é observado. O processo de estimação de β_0 e β_1 da Equação (8) é realizado por máxima verossimilhança. Por se tratar de um problema não linear, não há solução analítica fechada para esses estimadores, o R utiliza um procedimento numérico chamado mínimos quadrados iterativamente ponderados, ou IRLS. A ideia desse algoritmo é aproximar, a cada iteração, o problema não linear da regressão logística por um problema de mínimos quadrados ponderados (Maalouf, 2011).

Partindo de valores iniciais para os parâmetros da regressão, calcula-se na iteração t , as atualizações de η_i e $q_i \forall i = 1, 2, \dots, n$, baseadas na Equação (8).

$$\eta_i^{(t)} = \beta_0^{(t)} + \beta_1^{(t)} \hat{\theta}_i, \quad q_i^{(t)} = \frac{1}{1 + \exp[-\eta_i^{(t)}]}.$$

Em seguida, define-se a regra de atualização de uma variável resposta pseudo-observada por:

$$x_i^{(t)} = \eta_i^{(t)} + \frac{w_i - q_i^{(t)}}{q_i^{(t)} (1 - q_i^{(t)})}.$$

Além disso, são definidos os pesos para o reponderamento a cada iteração como $\omega_i^{(t)} = q_i^{(t)} (1 - q_i^{(t)})$. Com isso, resolve-se uma regressão linear ponderada de $x_i^{(t)}$ sobre w_i com pesos $\omega_i^{(t)}$. Matricialmente, seja $\boldsymbol{\beta} = (\beta_0, \beta_1)^\top$, $\mathbf{W}$ a matriz de planejamento com uma coluna de uns e uma coluna contendo w_i , $\boldsymbol{\Omega}$ é uma matriz diagonal com os pesos $\omega_i^{(t)}$, $\mathbf{x}^{(t)} = (x_1^{(t)}, x_2^{(t)}, \dots, x_n^{(t)})^\top$ o vetor da resposta pseudo-observada, a regra de atualização de $\boldsymbol{\beta}$ é dada por:

$$\boldsymbol{\beta}^{(t+1)} = (\mathbf{W}^\top \boldsymbol{\Omega}^{(t)} \mathbf{W})^{-1} \mathbf{W}^\top \boldsymbol{\Omega}^{(t)} \mathbf{x}^{(t)}.$$

O processo é repetido até que os parâmetros praticamente não mudem mais entre uma iteração e outra, ou até que a log-verossimilhança deixe de apresentar melhora relevante. Essa etapa do processo de estimação é realizada com apoio do algoritmo de mínimos quadrados iterativamente reponderados e é implementado via função `glm()` no R.

2.3.2 Estimação Simultânea

Alternativamente à abordagem em duas etapas, o método de estimação simultânea estima conjuntamente os parâmetros da TRI e da regressão. Para tanto, foi utilizada a abordagem bayesiana a qual possibilita encontrar a distribuição à posteriori dos parâmetros condicionada aos dados observados (Dempster, 1968). Para implementar esse método, é necessário saber as verossimilhanças (i.e., distribuição dos dados observados) de Z_{ij} e de W_i , bem como as distribuições à priori dos parâmetros da TRI e da regressão.

O procedimento de estimação simultânea é derivado do *framework* desenvolvido por Patz e Junker (1999) que permite estimar a variável latente e os parâmetros dos itens simultaneamente, não havendo a necessidade de calibrar a TRI para depois estimar o traço latente. Consequentemente, também é possível escrever a formulação do Modelo Estrutural conforme apresentado na Figura 1 e estimar todos os parâmetros conjuntamente. Desse modo, considera-se $\boldsymbol{\Psi} = \{\theta_1, \theta_2, \dots, \theta_n, a_1, a_2, \dots, a_p, b_1, b_2, \dots, b_p, \alpha_1, \alpha_2, \dots, \alpha_p\}$ o vetor de parâmetros de interesse para o CRM.

A verossimilhança de Z pode ser obtida à partir da Equação (3), ao considerar uma amostra aleatória na qual Z_{ij} é obtido pela transformação da Equação (1). A log-verossimilhança de Z é dada por:

$$\ell(Z, \boldsymbol{\Psi}) = \sum_{i=1}^n \sum_{j=1}^p \left[\ln(a_j) - \ln(\alpha_j) - \frac{1}{2} \ln(2\pi) - \frac{a_j^2}{2\alpha_j^2} \{z_{ij} - \alpha_j(\theta_i - b_j)\}^2 \right]. \quad (9)$$

No caso de W_i , θ_i que é estimado com base em Y_{ij} observados é usado para estimar β_0 e β_1 . Desse modo, a Equação (4) é reescrita como:

$$\eta_i = \ln \left[\frac{P(W_i = 1 | \theta_i)}{1 - P(W_i = 1 | \theta_i)} \right] = \beta_0 + \beta_1 \theta_i. \quad (10)$$

Analogamente, a distribuição de $W_i | \theta_i, \beta_0, \beta_1$ é definida por:

$$W_i | \theta_i, \beta_0, \beta_1 \sim \text{Bern}(Q_i).$$

Igualmente para o CRM, seja $\Phi = \{\beta_0, \beta_1\}$ o vetor de parâmetros de interesse da regressão estrutural. A log-verossimilhança de W é definida por:

$$\ell(W, \Phi) = \sum_{i=1}^n [w_i (\beta_0 + \beta_1 \theta_i) - \ln(1 + \exp(\beta_0 + \beta_1 \theta_i))]. \quad (11)$$

Em relação às prioris, definiu-se $\theta_i \sim \mathcal{N}(0, 1)$, portanto, de acordo com os pressupostos usuais para a distribuição da variável latente. Para os parâmetros dos itens, foram adotadas prioris vagas, de tal forma que $a_j \sim \mathcal{N}_+(1, \tau_a^{-2})$, $b_j \sim \mathcal{N}(0, \tau_b^{-2})$, $\alpha_j \sim \mathcal{N}_+(1, \tau_\alpha^{-2})$ com $\tau_a^{-2} = \tau_b^{-2} = \tau_\alpha^{-2} = 10^{-3}$. Similarmente, foram adotadas prioris não informativas para os parâmetros da regressão, sendo $\beta_0, \beta_1 \sim \mathcal{N}(0, 10^3)$.

Assim sendo, considerando $\Theta = \{\Psi, \Phi\}$ o vetor de parâmetros de interesse do método conjunto, define-se $\pi(\Theta | Z, W)$ como a distribuição a posteriori dos parâmetros de interesse como:

$$\pi(\Theta | Z, W) = \frac{f(Z, W | \Theta)\pi(\Theta)}{m(Z, W)}, \quad (12)$$

em que:

1. $f(Z, W | \Theta)$ é a verossimilhança conjunta dos dados observados.
2. $\pi(\Theta)$ é a distribuição à priori conjunta dos parâmetros.
3. $m(Z, W)$ é a constante normalizadora, de tal forma que $m(Z, W) = \int f(Z, W | \Theta)\pi(\Theta)d\Theta$.

Em se tratando especificamente da estimação de β_1 , que é o foco deste trabalho, a posteriori de β_1 é proporcional aos termos que dependem apenas de β_1 , podendo ser desenvolvida à partir da Equação (12).

$$\pi(\beta_1 | \text{resto}) \propto \exp\left\{-\frac{\beta_1^2}{2 \times 1000}\right\} \prod_{i=1}^n \frac{\exp\{w_i(\beta_0 + \beta_1 \theta_i)\}}{1 + (\beta_0 + \beta_1 \theta_i)}, \quad (13)$$

em que “resto” são todos os outros parâmetros pertencentes à Θ exceto β_1 , o primeiro termo da expressão representa a priori não informativa de β_1 e o segundo termo é a verossimilhança de W . Importante observar que, condicionando a θ_i e β_0 , a distribuição de Z e os parâmetros dos itens não aparecem diretamente na Equação (13). Entretanto, eles afetam indiretamente β_1 visto que determinam a distribuição posterior de θ_i . Após uns tratamentos algébricos, a Equação (13) pode ser escrita do seguinte modo:

$$\ln \pi(\beta_1 | \text{resto}) = -\frac{\beta_1^2}{2000} + \beta_1 \sum_{i=1}^n w_i \theta_i - \sum_{i=1}^n \ln \{1 + \exp(\beta_0 + \beta_1 \theta_i)\} + C. \quad (14)$$

em que C é um termo constante que não depende de β_1 . Como pode ser observado na Equação (14), não é trivial encontrar a distribuição a posteriori de um parâmetro de interesse analiticamente (Jackman, 2000), sobretudo neste cenário envolvendo modelo de mensuração com regressão estrutural. Desse modo, a distribuição a posteriori conjunta para todos os parâmetros é obtida via método de Monte Carlo por Cadeias de Markov (MCMC) (Metropolis *et al.*, 1953; Hastings, 1970). O objetivo do MCMC é gerar uma sequência de valores $\Theta^{(1)}, \Theta^{(2)}, \dots, \Theta^{(s)}$ tal que, após um período inicial de adaptação e convergência, esses valores possam ser tratados como amostras da distribuição posterior $\pi(\Theta | Z, W)$, descrita na Equação (12).

Não obstante, essas amostras não são independentes como em uma amostra aleatória simples. Elas formam uma cadeia de Markov, isto é, o valor sorteado na iteração atual depende do valor sorteado na iteração anterior. Neste processo, os dados observados em Y e W permanecem fixos, o que muda, a cada iteração, são os valores sorteados para Θ . Os valores iniciais $\Theta^{(0)}$ para cada cadeia de Markov foram fixados como:

$$\Theta^{(0)} = \{\theta^{(0)} = 0, a^{(0)} = 1, b^{(0)} = 0, \alpha^{(0)} = 1, \beta_0^{(0)} = 0, \beta_1^{(0)} = 0\}.$$

Os valores iniciais foram os mesmos para todo $i = 1, 2, \dots, n$, no caso de θ , e para todo $j = 1, 2, \dots, p$, no caso dos parâmetros dos itens. Apesar de fixos, esses valores iniciais se mostraram suficientemente bons para assegurar convergência das cadeias de Markov em poucas iterações. Em se tratando da estimação de β_1 , a cada iteração do MCMC, β_1 é reamostrado considerando os valores correntes de θ_i . No entanto, em contraste ao método de estimação em duas etapas, θ_i também são reamostrados com base tanto nas respostas aos itens do teste. Por conseguinte, a distribuição a posteriori de β_1 incorpora a incerteza da mensuração do traço latente em vez de tratá-lo observado.

Para estimar os parâmetros de interesse pelo método conjunto foi necessário o auxílio do programa JAGS (*Just Another Gibbs Sampler*) (Plummer, 2017) via pacote `rjags` (Plummer et al., 2025) no software estatístico R. No processo de estimação, três cadeias de markov foram utilizadas, com 2000 iterações de adaptação, mais 2000 iterações de *burn-in* para reduzir ao máximo a influência dos valores iniciais, se houver. Assim, 4000 amostras efetivas por cadeia foram utilizadas para cada parâmetro de interesse, totalizando um tamanho amostral de 12000 por parâmetro. O estimador de bayes utilizado para todos os parâmetros foi a média das amostras efetivas. O diagnóstico de convergência das cadeias de Markov foi feito com o apoio do pacote `coda` (Plummer et al., 2006).

2.4 Estudo com Dados Simulados

Para comparar os métodos descritos nas subseções 2.3.1 e 2.3.2, foi realizado um estudo com dados simulados para avaliar a qualidade dos estimadores de ambos os métodos. Foi considerado um teste de $p = 10$ itens contínuos e quatro grupo de indivíduos com tamanhos amostrais distintos, com $n_1 = 100, n_2 = 250, n_3 = 500, n_4 = 1000$. A variação do tamanho amostral é importante para comparar como os métodos se comportam em pequenas e em grandes amostras.

Os parâmetros dos itens foram gerados de acordo com as seguintes distribuições: $a, \alpha \sim \mathcal{U}(0.3, 2.5)$, $b \sim \mathcal{N}(0, 1)$. A variável latente também foi gerada à partir de uma Normal padrão, ou seja, $\theta \sim \mathcal{N}(0, 1)$. Em se tratando dos parâmetros da regressão, foram fixados os seguintes valores: $\beta_0 = 0.2, \beta_1 = 1.5$. 1000 replicatas aleatórias de Y e W foram geradas à partir dos parâmetros gerados aleatoriamente. O foco das simulações é comparar o valor verdadeiro de β_1 com os valores de $\hat{\beta}_1$.


Não obstante, é importante observar se o método de estimação simultânea também está estimando corretamente os parâmetros dos itens e a variável latente. Sendo assim, métricas como viés absoluto e raiz do erro quadrático médio (RMSE) foram utilizadas para avaliar exatidão e precisão dos estimadores, respectivamente.

3 Resultados Numéricos

A avaliação numérica teve como finalidade, a comparação do desempenho da estimação frequentista em duas etapas e da estimação bayesiana conjunta conforme discutido

na seção 2. A Figura 2 indica um comportamento distinto entre os dois métodos ao longo dos cenários amostrais.

Figura 2: Comparação das estimativas de β_1 em relação ao valor verdadeiro (linha tracejada) para cada cenário simulado testado.



Em tamanhos amostrais menores ($n = 100$ e $n = 250$), a estimação bayesiana conjunta apresenta maior dispersão e tende a superestimar β_1 . Esse resultado sugere que, em pequenas amostras, a estimação simultânea dos parâmetros dos itens, dos traços latentes individuais e dos parâmetros da regressão pode produzir instabilidade adicional. Como o modelo conjunto propaga a incerteza de θ diretamente para a regressão estrutural, a estimação de β_1 passa a depender fortemente da identificação conjunta da escala latente, dos parâmetros dos itens e da relação com o desfecho.

Curiosamente, para esses mesmos tamanhos amostrais, as estimativas de β_1 pelo método de estimação em duas etapas se concentram mais em torno do valor verdadeiro quando comparadas ao método conjunto. Em contrapartida, à medida que o tamanho amostral aumenta ($n = 500$ e $n = 1000$), é observada a tendência de subestimação do efeito do traço latente sobre a resposta distal a qual foi apontada na seção 1.

Por outro lado, para amostras maiores ($n = 500$ e $n = 1000$), nota-se uma melhora expressiva no comportamento da estimação conjunta, cujas estimativas de β_1 se concentram mais próximas do valor verdadeiro com redução clara da dispersão entre as replicações. Esse padrão é compatível com a expectativa de que a estimação simultânea se beneficie do aumento de informação amostral, pois amostras maiores fornecem mais evidência tanto para a identificação do traço latente quanto para a estimação da associação estrutural entre θ e W .

Além disso, a Tabela 1 avalia a qualidade dos estimadores dos parâmetros dos itens em ambos os métodos testados no estudo com dados simulados.

A análise dos resultados da Tabela 1 conclui que não houve mudanças substanciais no vício ou RMSE das estimativas dos parâmetros dos itens quando ambos os métodos são comparados. Essa é uma conclusão importante, visto que a permite inferir que a estimação simultânea do CRM e da regressão não afeta a estimação dos parâmetros dos itens. Desse


Tabela 1: Comparação entre os métodos de estimação em duas etapas e conjunto para os parâmetros dos itens no CRM.

n	Método	Vicio			RMSE		
		$\hat{a}$	$\hat{b}$	$\hat{\alpha}$	$\hat{a}$	$\hat{b}$	$\hat{\alpha}$
100	Duas etapas	0.0531	-0.0118	0.0187	0.1856	0.1676	0.0805
	Conjunto	0.1566	-0.0135	0.0885	0.2486	0.1933	0.1260
250	Duas etapas	0.0411	-0.0422	0.0216	0.1162	0.1126	0.0547
	Conjunto	0.0793	-0.0426	0.0477	0.1375	0.1219	0.0719
500	Duas etapas	-0.0189	0.0104	-0.0159	0.0776	0.0797	0.0387
	Conjunto	-0.0012	0.0100	-0.0037	0.0763	0.0762	0.0358
1000	Duas etapas	0.0071	0.0318	0.0019	0.1243	0.0621	0.0261
	Conjunto	0.0173	0.0314	0.0081	0.1605	0.0626	0.0278

modo, permanece-se preservada uma das grandes vantagens de se usar a TRI, que é a interpretação de cada um dos itens de um teste através de seus parâmetros de discriminação, dificuldade ou de escala.

Outro ponto importante da análise é a estimação do traço latente para todos os n indivíduos, haja vista que o traço latente é o preditor da regressão logística e, portanto, imprescindível para explicar o comportamento de $\hat{\beta}_1$ observado na Figura 2.

Figura 3: Comparação das estimativas médias dos θ_i em relação ao seu respectivo valor verdadeiro para cada cenário simulado testado.



A Figura 3 mostra que, em todos os cenários, a média dos $\hat{\theta}_i$ se alinha de forma bastante próxima aos respectivos valores verdadeiros. A nuvem de pontos acompanha a reta de identidade, sugerindo que tanto o método em duas etapas quanto o método conjunto preservam bem a ordenação dos indivíduos no traço latente. Em contrapartida, a principal

diferença entre os métodos não está na média, mas na dispersão. No método em duas etapas, o desvio-padrão dos $\hat{\theta}_i$ fica praticamente igual a 1 em todos os tamanhos amostrais simulados. No entanto, os desvios-padrão são menores: 0.918, 0.957, 0.968 e 0.974, respectivamente. Isso sugere uma contração dos $\hat{\theta}_i$ no método conjunto, isto é, os valores estimados tendem a ficar um pouco mais concentrados em torno de zero.

Em se tratando de como a estimação do traço latente afeta o comportamento de $\hat{\beta}_1$, nos cenários menores, especialmente $n = 100$ e $n = 250$, o método conjunto apresentou maior dispersão e tendência de superestimação de β_1 . Isso pode estar relacionado ao fato de que, nesses cenários, os θ s estimados pelo método conjunto estão mais comprimidos em relação à escala verdadeira. Quando a variável latente usada na regressão tem menor variabilidade, o coeficiente associado a ela pode aumentar para representar a mesma relação com o desfecho, contribuindo para estimativas maiores de β_1 . Adicionalmente, em pequenas amostras, a estimação simultânea da variável latente, parâmetros dos itens e parâmetros da regressão adiciona instabilidade, o que se reflete na maior dispersão dos *boxplots*.

4 Conclusão e Trabalhos Futuros

Os resultados apresentados na seção 3 demonstram que, de fato, tratar uma variável latente como observada incorre na subestimação de seu efeito sobre uma outra variável mensurada diretamente. Isso pode ser verificado na análise da Figura 2, sobretudo em tamanhos amostrais maiores. Como solução, a estimação conjunta da TRI e da regressão parece atenuar o problema do viés de $\hat{\beta}_1$, principalmente considerando amostras grandes. Além disso, conforme visto na Tabela 1, não existe prejuízo significativo da estimação dos parâmetros dos itens no método de estimação conjunta quando comparado à estimação em duas etapas. Desse modo, pode-se dizer que assintoticamente o método de estimação conjunta apresenta propriedades satisfatórias e tende a ser melhor que a estimação em duas etapas.

Entretanto, alguns problemas ainda precisam ser estudados em relação ao método de estimação conjunta. Em primeiro lugar, essa abordagem é mais instável na estimação de β_1 quando o tamanho amostral é menor, inclusive, apontando o método de estimação em duas etapas como mais estável e menos viesado. Em segundo, a estimação conjunta pelo método bayesiano ligeiramente subestima a dispersão dos θ_i , principalmente em tamanhos amostrais menores. Isso pode ser um fator que explica superestimação excessiva de β_1 pelo método conjunto em pequenas amostras. Portanto, há de se estudar melhorias para a estimação simultânea, sobretudo em pequenas amostras.

Uma possível solução é adotar um sistema de prioris hierárquicas para o CRM, conforme já testado em outros modelos da TRI (Kim e Bolt, 2007; Natesan *et al.*, 2016). Ao adotar prioris para os hiperparâmetros de média e precisão do traço latente e dos parâmetros dos itens pode ser interessante para corrigir o problema de subestimação ou superestimação de θ_i extremos. Dessa forma, isso pode diminuir a instabilidade da estimação de β_1 na estimação simultânea, podendo produzir resultados similares, ou até melhores, que a estimação em duas etapas.

Outro aspecto a ser observado é se a magnitude do viés de $\hat{\beta}_1$ é alterada de acordo com o valor de β_1 . Ou seja, se o traço latente possui um efeito maior sobre a resposta distal, pode ser que as estimativas desse efeito no método conjunto pode ficar mais instável à medida que o valor verdadeiro de β_1 seja maior. Da mesma forma, pode ser que a subestimação de β_1 também seja de maior magnitude quando se estima o modelo em duas etapas considerando β_1 maiores.

Por conseguinte, como trabalhos futuros a serem propostos estão a estimação conjunta do CRM e da regressão utilizando outros sistemas de prioris, sobretudo prioris hierárquicas e com diferentes valores de β_1 . Há de se destacar também a importância de se utilizar ferramentas estatísticas mais recentes e com um poder computacional melhor, como é o caso do **stan** (Gabry *et al.*, 2025). Outras questões podem ser consideradas futuramente como presença de dados ausentes, θ de distribuições não normais, presença de covariáveis na TRI, dentre outros aspectos.

Referências

- Andrich, D. (1978). A rating formulation for ordered response categories. *Psychometrika*, **43**(4), 561–573.
- Birnbaum, A. (1968). Some latent trait models. *Statistical theories of mental test scores*.
- Bock, R. D. (1972). Estimating item parameters and latent ability when responses are scored in two or more nominal categories. *Psychometrika*, **37**(1), 29–51.
- Bolck, A., Croon, M., e Hagenaars, J. (2004). Estimating latent structure models with categorical variables: One-step versus three-step estimators. *Political Analysis*, **12**(1), 3–27.
- Bollen, K. A. (1989). *Structural equations with latent variables*. John Wiley & Sons.
- Cella, D. F. e Perry, S. W. (1986). Reliability and concurrent validity of three visual-analogue mood scales. *Psychological reports*, **59**(2), 827–833.
- Cox, D. R. e Hinkley, D. V. (1979). *Theoretical statistics*. CRC Press.
- Dempster, A. P. (1968). A generalization of bayesian inference. *Journal of the Royal Statistical Society: Series B (Methodological)*, **30**(2), 205–232.
- Dempster, A. P., Laird, N. M., e Rubin, D. B. (1977). Maximum likelihood from incomplete data via the em algorithm. *Journal of the royal statistical society: series B (methodological)*, **39**(1), 1–22.
- Devlieger, I., Mayer, A., e Rosseel, Y. (2016). Hypothesis testing using factor score regression: A comparison of four methods. *Educational and Psychological Measurement*, **76**(5), 741–770.
- Ferrando, P. J. (1999). Likert scaling using continuous, censored, and graded response models: Effects on criterion-related validity. *Applied Psychological Measurement*, **23**(2), 161–175.
- Ferrando, P. J. (2001). A nonlinear congeneric model for continuous item responses. *British Journal of Mathematical and Statistical Psychology*, **54**(2), 293–313.
- Ferrando, P. J. (2002). Theoretical and empirical comparisons between two models for continuous item response. *Multivariate Behavioral Research*, **37**(4), 521–542.
- Ferrando, P. J. (2010). Some statistics for assessing person-fit based on continuous-response models. *Applied Psychological Measurement*, **34**(4), 219–237.

- Ferrando, P. J. e Lorenzo-Seva, U. (2007). An item response theory model for incorporating response time data in binary personality items. *Applied Psychological Measurement*, **31**(6), 525–543.
- Filmer, D. e Scott, K. (2012). Assessing asset indices. *Demography*, **49**(1), 359–392.
- Fox, J.-P. (2010). *Bayesian item response modeling: Theory and applications*. Springer.
- Fox, J.-P. e Glas, C. A. W. (2003). Bayesian modeling of measurement error in predictor variables using item response theory. *Psychometrika*, **68**(2), 169–191.
- Gabry, J., Češnovar, R., Johnson, A., e Bröder, S. (2025). *cmdstanr: R Interface to 'CmdStan'*. R package version 0.9.0, <https://discourse.mc-stan.org>.
- Guyatt, G. H., Townsend, M., Berman, L. B., e Keller, J. L. (1987). A comparison of likert and visual analogue scales for measuring change in function. *Journal of chronic diseases*, **40**(12), 1129–1133.
- Hambleton, R. K., Swaminathan, H., e Rogers, H. J. (1991). *Fundamentals of item response theory*, volume 2. Sage.
- Hare, C. e Poole, K. T. (2018). Psychometric methods in political science. *The Wiley Handbook of Psychometric Testing: A Multidisciplinary Reference on Survey, Scale and Test Development*, pages 901–931.
- Hastings, W. K. (1970). Monte carlo sampling methods using markov chains and their applications.
- Hays, R. D., Liu, H., Spritzer, K., e Cella, D. (2007). Item response theory analyses of physical functioning items in the medical outcomes study. *Medical care*, **45**(5), S32–S38.
- Jackman, S. (2000). Estimation and inference via bayesian simulation: An introduction to markov chain monte carlo. *American journal of political science*, pages 375–404.
- Junker, B., Schofield, L. S., e Taylor, L. J. (2012). The use of cognitive ability measures as explanatory variables in regression analysis. *IZA Journal of Labor Economics*, **1**(1), 4.
- Kim, J.-S. e Bolt, D. M. (2007). Estimating item response theory models using markov chain monte carlo methods. *Educational Measurement: Issues and Practice*, **26**(4), 38–51.
- Kline, R. B. (1998). Structural equation modeling. *New York: Guilford*, **33**, 9780203108550–9.
- Knoll, M. A. e Houts, C. R. (2012). The financial knowledge scale: An application of item response theory to the assessment of financial literacy. *Journal of consumer affairs*, **46**(3), 381–410.
- Lord, F. (1952). A theory of test scores. *Psychometric monographs*.
- Maalouf, M. (2011). Logistic regression in data analysis: an overview. *International Journal of Data Analysis Techniques and Strategies*, **3**(3), 281–299.
- Masters, G. N. (1982). A rasch model for partial credit scoring. *Psychometrika*, **47**(2), 149–174.

- Mellenbergh, G. J. (1994). A unidimensional latent trait model for continuous item responses. *Multivariate Behavioral Research*, **29**(3), 223–236.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., e Teller, E. (1953). Equation of state calculations by fast computing machines. *The journal of chemical physics*, **21**(6), 1087–1092.
- Muraki, E. (1992). A generalized partial credit model: Application of an em algorithm. *ETS Research Report Series*, **1992**(1), i–30.
- Natesan, P., Nandakumar, R., Minka, T., e Rubright, J. D. (2016). Bayesian prior choice in irt estimation using mcmc and variational bayes. *Frontiers in psychology*, **7**, 1422.
- OCDE, O. (2008). Handbook on constructing composite indicators: Methodology and user guide. *European Commission*.
- Patz, R. J. e Junker, B. W. (1999). A straightforward approach to markov chain monte carlo methods for item response models. *Journal of educational and behavioral Statistics*, **24**(2), 146–178.
- Plummer, M. (2017). Jags version 4.3. 0 user manual.
- Plummer, M., Best, N., Cowles, K., Vines, K., *et al.* (2006). Coda: convergence diagnosis and output analysis for mcmc. *R news*, **6**(1), 7–11.
- Plummer, M., Stukalov, A., e Denwood, M. (2025). *rjags: Bayesian Graphical Models using MCMC*. CRAN, Vienna, Austria. R package version 4-17.
- Rasch, G. (1960). *Probabilistic Models for Some Intelligence and Attainment Tests*. Danish Institute for Educational Research, Copenhagen.
- Roskam, E. E. (1997). Models for speed and time-limit tests. In *Handbook of modern item response theory*, pages 187–208. Springer.
- Samejima, F. (1969). Estimation of latent ability using a response pattern of graded scores. *Psychometrika*, **34**(S1), 1–97.
- Samejima, F. (1973). Homogeneous case of the continuous response model. *Psychometrika*, **38**(2), 203–219.
- Samejima, F. (1974). Normal ogive model on the continuous response level in the multidimensional latent space. *Psychometrika*, **39**(1), 111–121.
- Schofield, L. S. (2008). *Modeling measurement error when using cognitive test scores in social science research*. Ph.D. thesis, Carnegie Mellon University, Pittsburgh, Pennsylvania.
- Schofield, L. S., Junker, B., Taylor, L. J., e Black, D. A. (2015). Predictive inference using latent variables with covariates. *Psychometrika*, **80**(3), 727–747.
- Shojima, K. (2005). A noniterative item parameter solution in each em cycle of the continuous response model. *Educational technology research*, **28**(1-2), 11–22.
- Skrondal, A. e Laake, P. (2001). Regression among factor scores. *Psychometrika*, **66**(4), 563–575.

- Spearman, C. (1904). 'general intelligence,' objectively determined and measured. *The American Journal of Psychology*, **15**(2), 201–293.
- Tutz, G. e Jordan, P. (2024). Latent trait item response models for continuous responses. *Journal of Educational and Behavioral Statistics*, **49**(4), 499–532.
- Van der Linden, W. J. (2006). A lognormal model for response times on test items. *Journal of Educational and Behavioral Statistics*, **31**(2), 181–204.
- Vandemoortele, M. (2014). Measuring household wealth with latent trait modelling: An application to malawian dhs data. *Social Indicators Research*, **118**(2), 877–891.
- Wang, T. e Zeng, L. (1998). Item parameter estimation for a continuous response model using an em algorithm. *Applied Psychological Measurement*, **22**(4), 333–344.
- Zhang, X., Wang, C., Weiss, D. J., e Tao, J. (2021). Bayesian inference for irt models with non-normal latent trait distributions. *Multivariate Behavioral Research*, **56**(5), 703–723.
- Zopluoglu, C. (2012). Estcrm: An r package for samejima's continuous irt model. *Applied Psychological Measurement*, **36**(2), 149.